

# Modelos generativos

## GANs y VAEs

# GAN: Generative Adversarial Nets




*"Adversarial training is the coolest idea in Machine Learning in the last 20 years"*

**Yann Lecun**

Vice President, Chief AI Scientist en Facebook  
Professor at New York University  
Founding director of the NYU Center for Data Science

# Real or Fake?






# Real or Fake?




# Aprendizaje no supervisado

Clustering: encontrar grupos en los datos (colores)



# Aprendizaje no supervisado

Clustering: encontrar grupos en los datos (colores)



Modelos generativos: encontrar la función  $P(X)$  que generó los datos

Dos tipos: Explícitos e Implícitos

*“What I cannot create, I do not understand.”*

—Richard Feynman

# 2014



---

## Generative Adversarial Nets

---

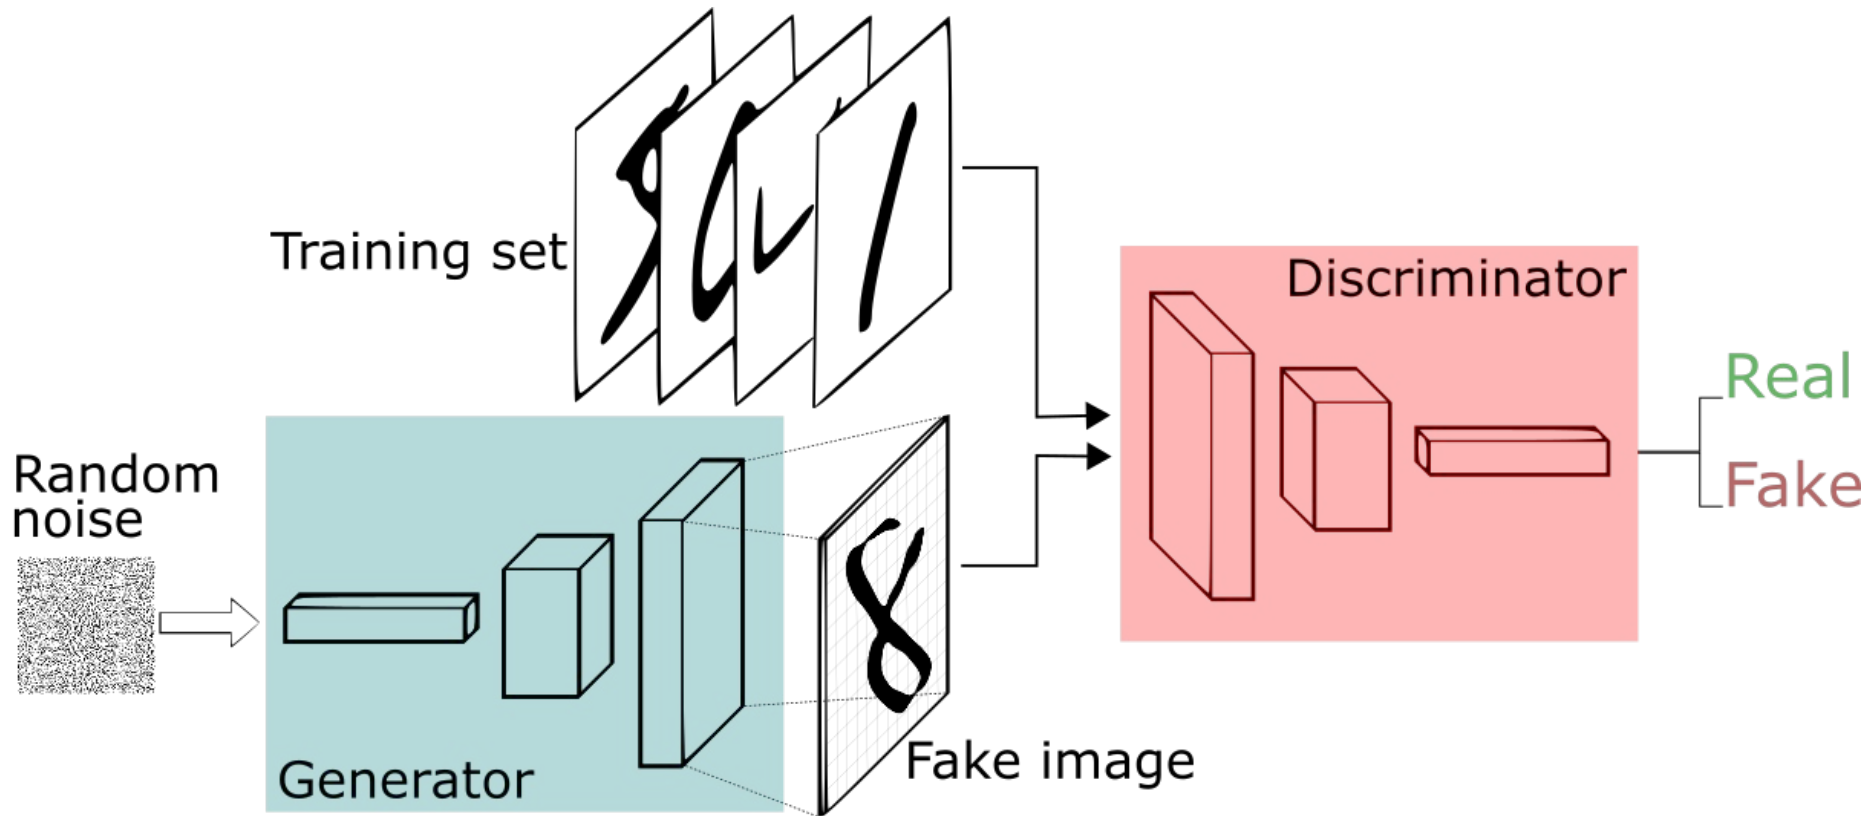
**Ian J. Goodfellow<sup>\*</sup>, Jean Pouget-Abadie<sup>†</sup>, Mehdi Mirza, Bing Xu, David Warde-Farley,  
Sherjil Ozair<sup>‡</sup>, Aaron Courville, Yoshua Bengio<sup>§</sup>**

Département d'informatique et de recherche opérationnelle  
Université de Montréal  
Montréal, QC H3C 3J7

**Ian Goodfellow**

Deep learner. Inventor of GANs. Lead author of  
<http://www.deeplearningbook.org>

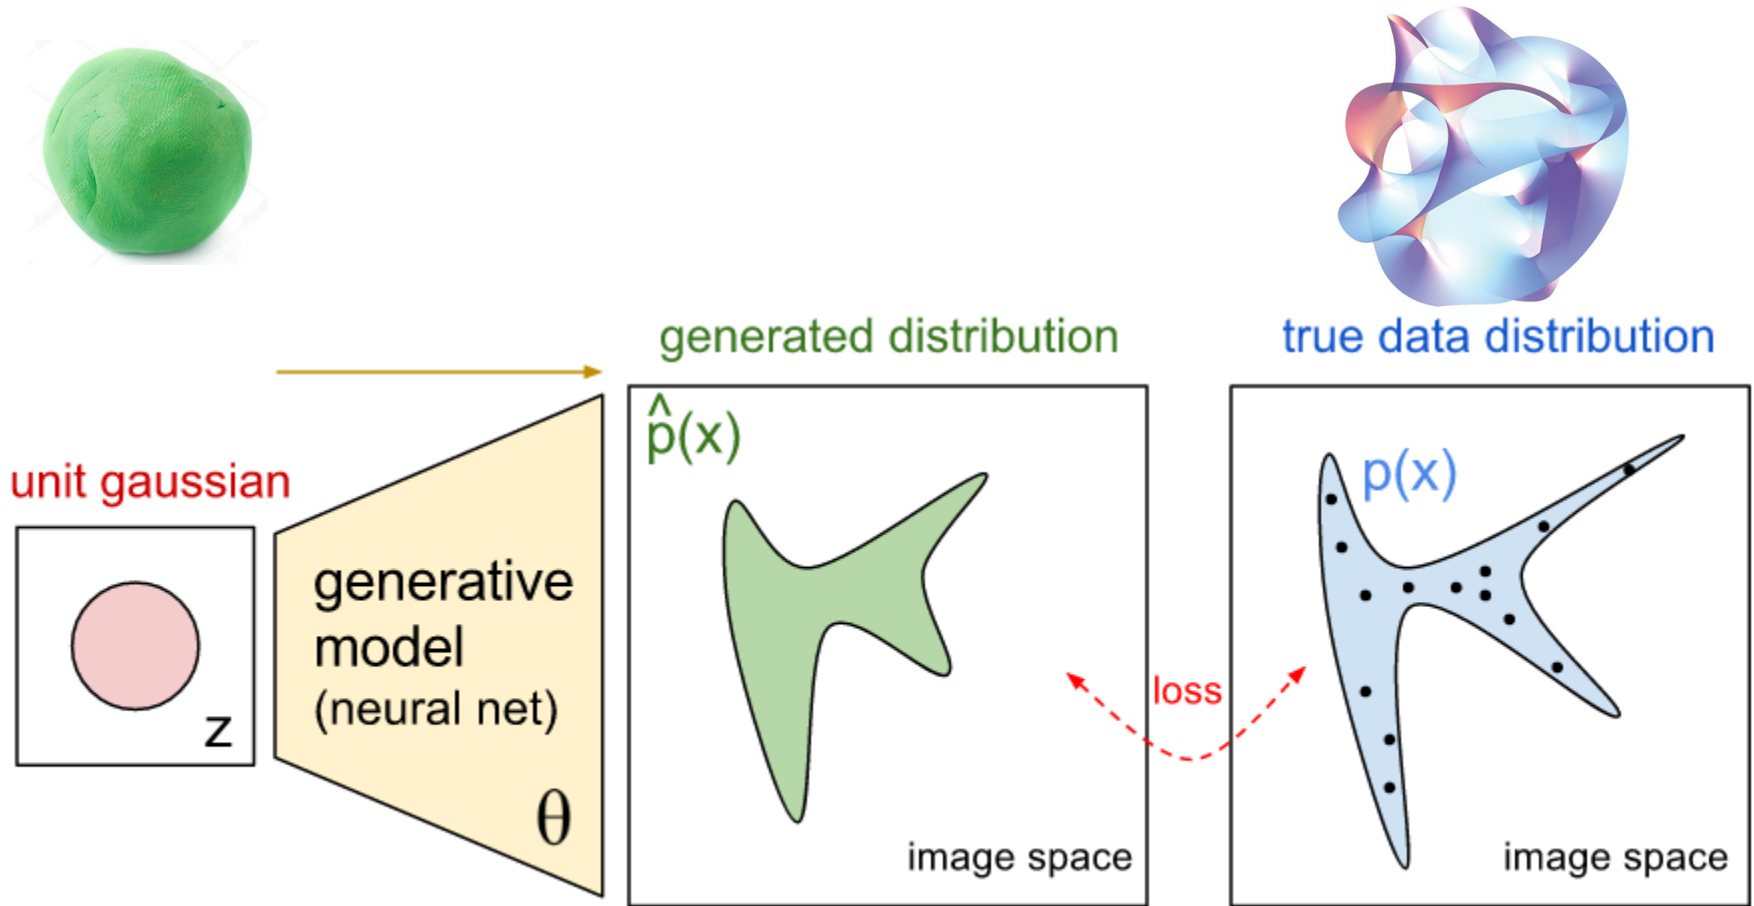
# Generative Adversarial Nets (GAN)



$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$



# Generative Adversarial Nets (GAN)




Kullback–Leibler divergence


$$KL(\mathbb{P}_r \parallel \mathbb{P}_g) = \int \log \left( \frac{P_r(x)}{P_g(x)} \right) P_r(x) d\mu(x)$$

# Deep Convolutional GAN (dcgan, 2015)

Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*.




# Aritmética de caras



Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. arXiv preprint arXiv:1511.06434.

# Interpolación



# La evolución de GAN (rostros)

GAN



2014

DCGAN



2015

CoGAN



2016

ProgGAN



2017

StyleGAN




2018



# La evolución de GAN (imágenes naturales)

2014

GAN




Ene. 2017

WGAN




Sep. 2017

SplittingGAN



Oct. 2017

ProgGAN



2018

BigGAN



Université   
de Montréal

 **NYU**  
**facebook**

CONICET  
  
C I F A S I S



 **NVIDIA.**

  
Google DeepMind

# BigGAN

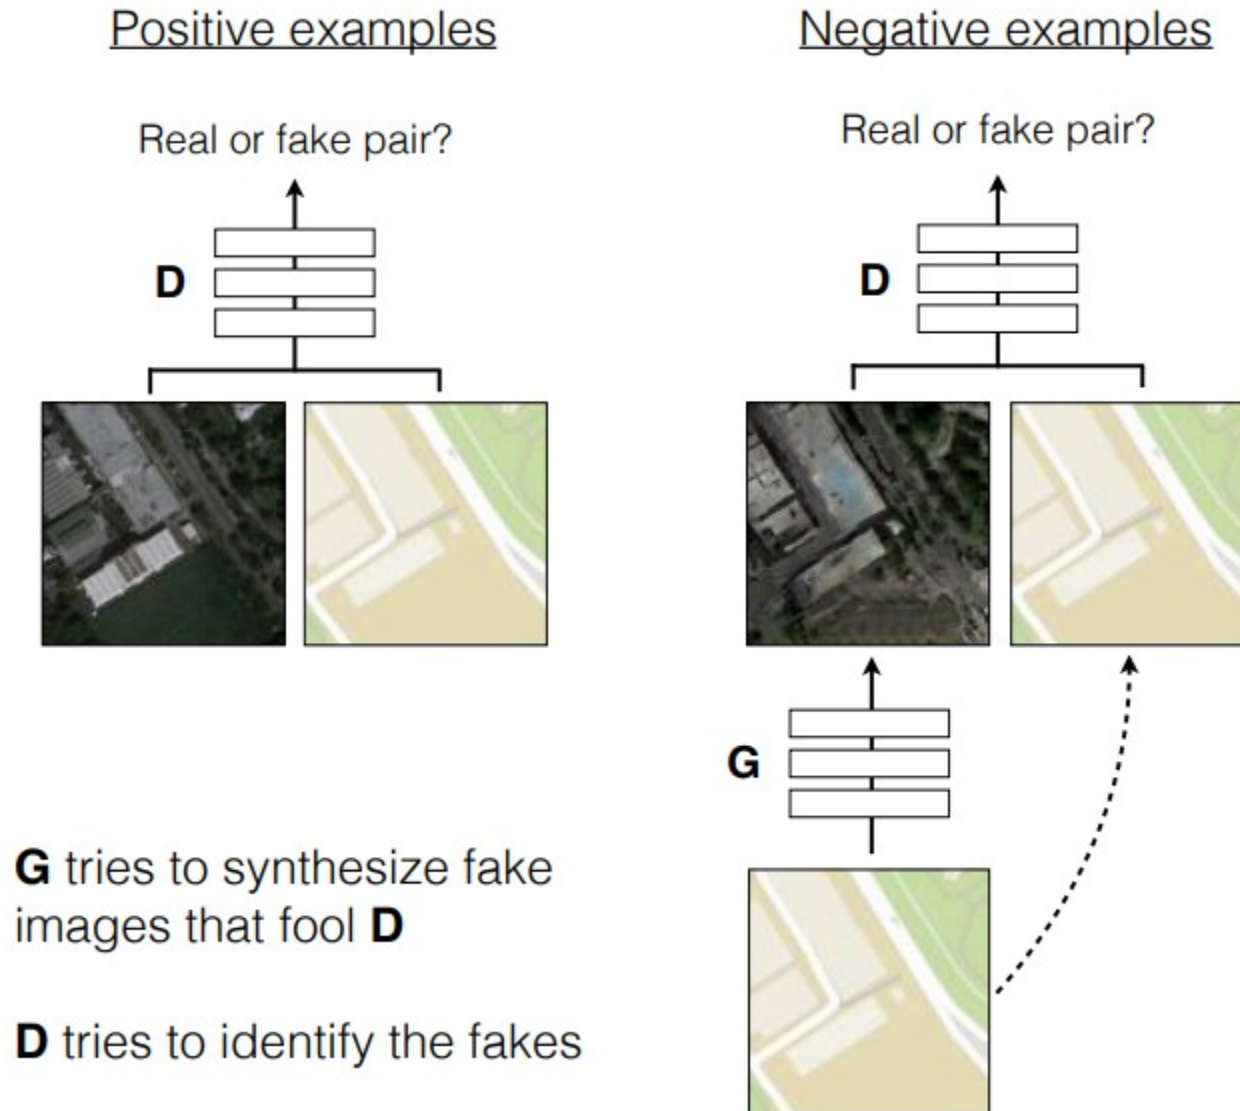


Brock, A., Donahue, J., & Simonyan, K. (2018). Large scale gan training for high fidelity natural image synthesis. arXiv preprint arXiv:1809.11096.

Algunas aplicaciones



# Image-to-Image Translation




# Image-to-Image Translation

Labels to Street Scene



Labels to Facade



BW to Color



Aerial to Map



Day to Night



Edges to Photo






# CycleGAN (2017)


**GANs:**

Gaussian noise  
 $z \sim N(0,1)$



Gaussian noise  $\rightarrow$  target data manifold

**CycleGANs:**



data manifold  $X \rightarrow$  data manifold  $Y$



**Unpaired Image-to-Image Translation  
using Cycle-Consistent Adversarial Networks**

# CycleGAN

Cats  $\leftrightarrow$  Dogs



**itok\_msi** produced cats  $\leftrightarrow$  dogs CycleGAN results with a local+global discriminator and a smaller cycle loss.

Animal Transfiguration



**Tatsuya Hatanaka** trained our method to translate black bears to pandas. See more examples and download the models at the **website**. **Matt Powell** performed transfiguration between different species of birds



orange  $\rightarrow$  apple

# Turning Fortnite into PUBG with CycleGAN

## CycleGAN conversion from Fortnite to PUBG



Fortnite



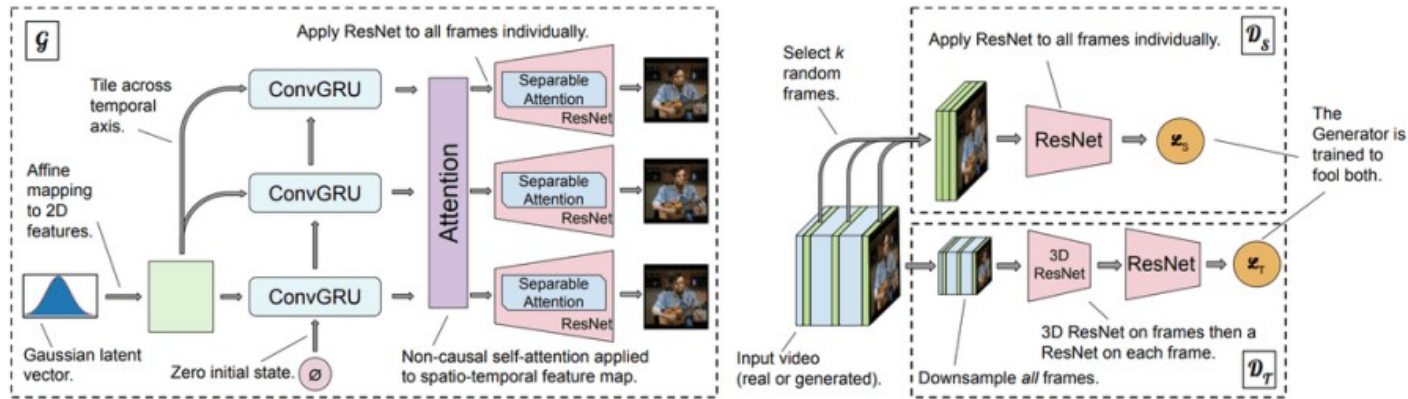
PUBG




FortG? PUBnite?




# Video: DVD-GAN (2019)



Big-GAN + Youtube +  
Discriminar en tiempo y espacio



# Living portraits





# Análisis Semántico en Rostros



Ejemplos de  
imágenes a  
clasificar



Caras  
generadas  
con GAN



Inteligencia Artificial

Iberoamerican Journal of Artificial Intelligence. Edited by Iberamia.

## Semantic analysis on faces using deep neural networks

Nicolás Federico Pellejero  
Guillermo Grinblat  
Lucas Uzal

DOI:

<https://doi.org/10.4114/intartif.vol21iss61pp14-29>

**Keywords:** Deep, Learning, Emotion,  
Recognition.

# Exploiting GAN Internal Capacity for High-Quality Reconstruction of Natural Images

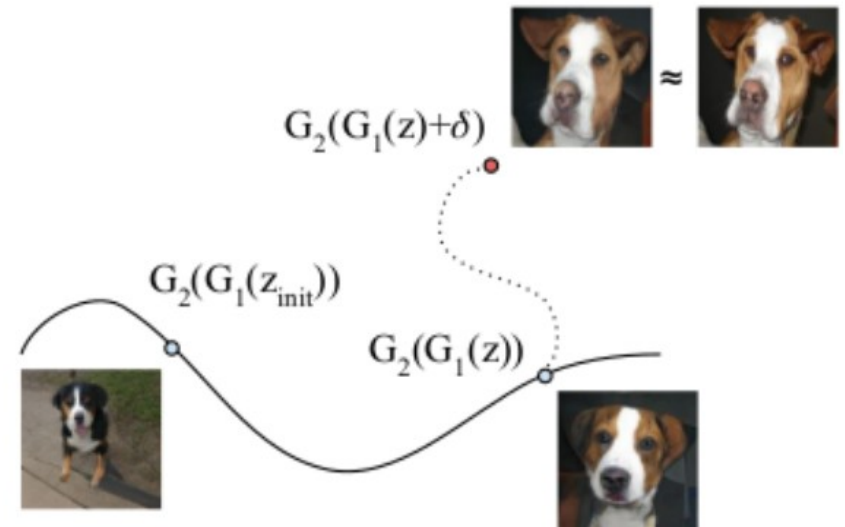

CONICET



C I F A S I S



Marcos Pividori  
Guillermo  
Grinblat  
Lucas Uzal



# Generación de rostros y manipulación de expresiones



# Autoencoders y VAEs



# Autoencoders

Variables latentes: Verdaderos factores de variación que explican un fenómeno observable.




*Myth of the Cave*




# Autoencoders

Encoder: modelo que transforma datos a vectores en un espacio de baja dimensión (espacio latente)



# Autoencoders


Decoder: modelo que transforma datos del espacio latente al espacio original



Autoencoder: modelo que transforma datos en sí mismos, pasando por un espacio latente.

# Autoencoders

Se utiliza una función costo que mide la calidad de la reproducción. No se necesitan datos con etiquetas.



# Autoencoders: puntos clave

El cuello de botella en la red obliga a aprender una representación de baja dimensionalidad.

La función costo obliga a reproducir la mayor cantidad posible de información de la entrada


Resultado: proyecciones simples con gran información





# Autoencoders variacionales VAE

Autoencoder con mejora: asume que la representación en el espacio latente es sampleada de una distribución.



# Autoencoder: generación


Se varía lentamente una de las variables latentes con las otras fijas.

Diferentes variables en  $Z$  suelen codificar diferentes factores de variación de los datos.



Head pose

# Autoencoder: generación



Queremos variables latentes independientes una de otra.

Se puede forzar al modelo para que aprenda variables “desenredadas”